


انهارده هنتكلم علي gaussian process وده موديل يعني .. و ده corresponds to bayesian linear regression when we use kernels
 هنتشوف ميزة الكيرنال ... فهي بتخلينا نقدر نحسب الدوت برضودكت من غير ما نروح لل new high dimensional space فنقدر نعمل ده بسرعه ..
 فتعال نشغل اكلام ده علي generalized linear model واول واحد هنتكلم عليه هو ال bayesian linear regression ومنين ما بتستخدم الكيرنالز في
 الكونتكتست ده .. ده بيودينا ناحية ال Gaussian process . ده اول جزء ... جاوسين بروسيسسز برضو بتبقا equivalent to a neural network اللي
 ليها one hidden layer بس بتبقا infinitely large ... ففي ربط ما بين الكلاسيك تكنيكس زي مثلا ال bayesian linear regression اللي هنتسميها
 دلوقت جاوسين بروسيس .. فده بيبقا مكافئ ل Bayesian learning in a neural network with 1 hidden layer whenever you've got an
 infinitely large hidden layer

طيب عشان نوضح ايه هي الجاوسين بروسيس خلينا نرسم صورته و بعدين نتكلم

احنا مهتمين بالرجريشن وعندنا داتا .. الانبوت هو الاكس اكسيس و الاوتبوت هو الواي اكسيس .. الفانكشن اللي انت عاوز تكتشفها هي الفانكشن اللي
 الدكتور راسمها .. انت عندك شوية داتا علي الخط اللي انت نفسك تجيبه ... احنا هنفترض ان الداتا مفهانش نويز و الواي الي بتقيسها ملهانش نويز .. فدلوقت
 لو بتعمل لينير ريجريشن مش هتقدر تجيب الفانكشن ديه عشان ديه فانكشن نان لينير ..



طيب لما كنا بنتكلم علي البايزين لينير ريجريشن .. لما كنا بنشتغل فيه فكنا بنفترض ان الفانكشن $f(x)$ بتبقا linear combinations of $\phi(x)$ و الاوتبوت
 $f(x)$ ده كان معاه شوية noise فطلعك ال y ... بص عالسلايد

Bayesian Linear Regression

- Setting: $f(x) = \mathbf{w}^T \phi(x)$ and $y = f(x) + \epsilon$
 \downarrow \downarrow
 unknown $N(0, \sigma^2)$

Weight space view:

- Prior: $\Pr(\mathbf{w})$
- Posterior: $\Pr(\mathbf{w} | \mathbf{X}, \mathbf{y}) = k \Pr(\mathbf{w}) \Pr(\mathbf{y} | \mathbf{w}, \mathbf{X})$

Gaussian


Gaussian

Gaussian

الـ جـانـمـ كـيـنـ عـي
 weights

دلوقت هنبص علي function space view فبدل ما هنفكر في ال \mathbf{w} هي الآن نوون .. دلوقت هنا الحاجه الي احنا بنحاول نعملها estimation هي
 الفانكشن نفسها $f(x)$.. الفانكشن نفسها بتعتمد علي شوية بارامترز \mathbf{w} عادي ... بس هنا هنتعامل مع ال f علي اساس انها ال unknown .. فلو هنعمل
 bayesian linear regression هنبدا بال prior over a function ده بيبقا زي اللي ف السلايد كدا ...

Bayesian Linear Regression



University of Waterloo

CS480/680 Spring 2019 Pascal Poupart

4

Gaussian Process

- According to the function view, there is a Gaussian at $f(x_*)$ for every x_* . Those Gaussians are correlated through w .
- What is the general form of $\Pr(f)$ (i.e., distribution over functions)?
- Answer: **Gaussian Process** (infinite dimensional Gaussian distribution)

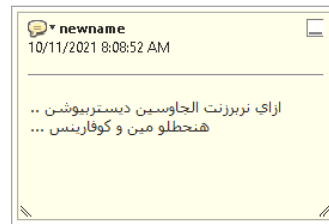
University of Waterloo

CS480/680 Spring 2019 Pascal Poupart

5

الدكتور يقول ان في correlation between gaussians through w .. ومن هنا بيحي ال kernel .. عشان لو انت لاحظت نقطه وانت عارف ان الفانكشن لازم تعدي بيها .. وكمان انت عارف ان في correlation between gaussians بالنسبه لل weights فانت لو خدت نقطه قيريه للنقطه اللي انت بتلاحظها دلوقت .. هتلاحظ uncertainty صغير جداً ... وده بيروح لفكرة ان لو انت عندك condition on a value for a given point عندك little uncertainty عندك فحشاش كذا في الرسمه اللي الدكتور راسمها .. هتلاقي عندك نقطه فعلاً قيريه .. هيبقا الاوتبوت بتاعها قريب جداً فبرضو هيبقا عندك uncertainty قيريه كذا في الرسمه اللي الدكتور راسمها .. هتلاقي ان الكيرفين بتوع ال $-\sigma$ and $+\sigma$ بيبعدو عن بعض .. بس في الاول هم بيقو قيريين من بعض وبعدين بيبدأو بالتدريج يبعدوا ... فانت فعلياً هتتوقع little uncertainty في الاول يعني ... الجاوسين بروسيس هي infinite number of Gaussian distributions all correlated together فده معناه انك عندك infinite multivariate Gaussian .. وده اللي اسمو Gaussian process

Gaussian Process



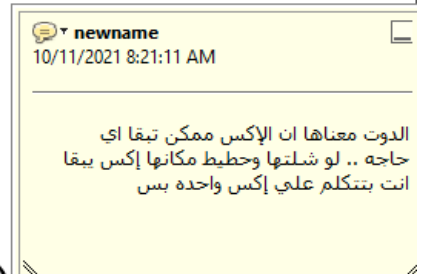
- Distribution over functions:

$$f(\mathbf{x}) \sim GP(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')) \forall \mathbf{x}, \mathbf{x}'$$

- Where $m(\mathbf{x}) = E(f(\mathbf{x}))$ is the mean
and $k(\mathbf{x}, \mathbf{x}') = E((f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}')))$ is
the kernel covariance function

Gaussian Process Regression

- Prior: $\Pr(f(\cdot)) = N(m(\cdot), k(\cdot, \cdot))$
- Likelihood: $\Pr(\mathbf{y}|\mathbf{X}, f) = N(f(\mathbf{X}), \sigma^2 \mathbf{I})$



- Posterior: $\Pr(f(\cdot)|\mathbf{X}, \mathbf{y}) = N(\bar{f}(\cdot), k'(\cdot, \cdot))$
where $\bar{f}(\cdot) = k(\cdot, \mathbf{X})(\mathbf{K} + \sigma^2 \mathbf{I})^{-1} \mathbf{y}$ and
 $k'(\cdot, \cdot) = k(\cdot, \cdot) + \sigma^2 \mathbf{I} - k(\cdot, \mathbf{X})(\mathbf{K} + \sigma^2 \mathbf{I})^{-1} k(\mathbf{X}, \cdot)$
- Prediction: $\Pr(y_*|\mathbf{x}_*, \mathbf{X}, \mathbf{y}) = N(\bar{f}(\mathbf{x}_*), k'(\mathbf{x}_*, \mathbf{x}_*))$
- Complexity: inversion of $\mathbf{K} + \sigma^2 \mathbf{I}$ is cubic in # of training points

